

Related Work 概述

用途：把 Related Work 里要引用的每篇研究"大致做了什么"逐条列出，并标注**对写作的用处/局限点**，方便后续用自己的语言凝练进报告。文献编号与《报告_写作指南与文献.md》一致。串写套路：每个方向一段——概述这一类方法（点名 2-3 篇代表作）→ 点出共同局限 → 过渡到下一方向或本文。

方向 1·传统图像处理与机器学习方法

Walter 等（2002）[3]—— 渗出液形态学检测的奠基工作之一。先定位并去除视盘（避免被误当渗出），再利用渗出液处局部灰度变化大的特点找出候选区域，最后用形态学重建得到精确轮廓。*用处/局限*：纯图像处理、无需训练，但严重依赖视盘定位和阈值，对光照/对比度变化敏感。

Sopharak 等（2008）[4]—— 在非散瞳眼底图上用数学形态学**无监督**地检测渗出液。同样先检测并排除视盘和血管，再用一系列形态学操作提取渗出。*用处/局限*：不需标注、速度快，但召回和精度受形态学算子与参数影响大，泛化有限。

Sánchez 等（2009）[6]—— 用**混合模型（统计建模）**检测硬性渗出液：对图像灰度分布建模，据此动态确定阈值把渗出从背景中分出。*用处/局限*：比固定阈值更自适应，但仍是基于强度的统计方法，难处理"亮而非渗出"的结构。

Giancardo 等（2012）[5]—— 把渗出液检测用于**糖尿病黄斑水肿（DME）的图像级判断**，提取与渗出相关的特征构造风险评分，并在多个公开数据集上验证。*用处/局限*：证明了渗出特征的临床价值与跨数据集可用性，但目标是图像级筛查，不是像素级精确分割。

Zhang 等（2014）[2]—— 本任务最关键的对照工作，也是 **e-ophtha EX 数据集的提出者**。流程为"预处理（归一化、去噪、反光/伪影检测）→ 形态学候选分割 → 经典特征 + 新颖上下文特征 → 随机森林分类"，在 e-ophtha EX 上取得 AUC 0.95。*用处/局限*：代表"候选 + 手工特征 + 分类器"三步法的最高水平，但仍依赖复杂的手工流程与特征设计——是引出深度学习/本文对比的最佳过渡点。

方向 2·深度学习方法

AlexNet（2012）[15]/VGG（2015）[16]/ResNet（2016）[14]—— 三个里程碑式的 CNN 骨干。AlexNet 在 ImageNet 2012 上确立深度 CNN 优势、开启深度学习时代；VGG 用堆叠的小卷积核证明"深度"能提升性能；ResNet 用残差/跳跃连接解决深层网络退化，使极深网络可训练。*用处*：作为背景说明深度学习兴起；本文所用 **ResNet34 编码器**出自 [14]。

U-Net（Ronneberger 等，2015）[13]—— 为生物学医学图像分割设计的编码器-解码器 + 跳跃连接网络，**靠数据增强在很少标注下也能训练**，已成为医学分割的事实标准。*用处*：本文方法主干，直接说明选它的理由（小样本 + 像素级分割）。

Gulshan 等（2016）[7]—— 用深度 CNN 在十几万张眼底图上训练，检测可转诊的糖尿病视网膜病变，灵敏度/特异度达到眼科医生水平，是 DL 用于 DR 的标志性临床研究（JAMA）。用

处：佐证深度学习在 DR 领域的潜力与价值。

Khojasteh 等 (2019) [8] —— 用**可学习的深度特征** (CNN 特征) 替代手工特征检测渗出液, 表明深度特征在该任务上优于传统手工特征。 *用处*：直接支撑"深度特征 > 手工特征"的论点。

Chudzik 等 (2018) [9] —— 用带 inception 模块的**全卷积网络 (FCN)** 做渗出液的像素级分割。 *用处*：说明已有工作把 FCN/分割网络用于渗出液，与本文 U-Net 思路同源。

方向 3·公开数据集

Decencière 等 (2013) [1] —— TeleOphta 项目，结合机器学习与图像处理做远程眼科筛查，提出 **e-ophtha 数据库** (e-ophtha EX 渗出液、e-ophtha MA 微动脉瘤)，数据来自 OPHDIAT 筛查网络、异质性强。 *用处*：介绍所用数据的来源（也是官方要求引用的出处）。

Porwal 等 (IDRiD, 2018) [22] —— 印度糖尿病视网膜病变图像数据集，提供 DR 病灶（含渗出）的**像素级标注**与分级标签，是病灶分割常用基准。 *用处 (可选)*：作为"其他公开像素级标注数据集"一笔带过，衬托数据稀缺背景。

方向 4·类别不平衡与损失

Salehi 等 (Tversky Loss, 2017) [18] —— 针对医学分割中"病灶体素远少于背景"的**类别不平衡**问题，提出基于 Tversky 指数的损失 (Dice 的推广)，通过 α/β 调节假阳/假阴权重，在精确率-召回率之间取得更好平衡、提升小病灶召回。 *用处*：直接支撑本文 U-Net 采用 Tversky ($\alpha=0.3$, $\beta=0.7$) 的设计动机。

串写示例（方向 1 收尾过渡）

"上述方法虽在 e-ophtha EX 上取得了不错的精度[2]，但普遍依赖人工设计的特征与候选检测流程，难以区分视盘、反光等'形似渗出'的结构——这促使研究者转向能自动学习特征、利用空间上下文的深度方法。"