

Raw (resized)




Preprocessed (illum-norm + CLAHE)



Ground truth



Overlay



---

# 视网膜眼底图像的渗出液分割

传统机器学习（逻辑回归 / SVM）与 U-Net 的对比研究

史大有+智能科学与技术+2435055016

# 目录

---

- 01 一、研究背景与任务
- 02 二、数据划分与预处理
- 03 三、实验方法与理论
- 04 四、结果与原因分析

## 研究背景与意义

- 糖尿病视网膜病变（DR）是全球主要致盲病因之一，且早期常无症状，**早筛早治至关重要**。
- **硬性渗出液**是 DR 最重要的早期标志物之一：视网膜血管渗漏形成的亮黄色脂质沉积斑块。
- 对渗出液**自动分割**，可支撑大规模筛查、量化病情、减轻医生阅片负担。
- 但筛查图像量巨大、人工标注昂贵——自动化方法是临床刚需。

## 任务定义与核心难点

**任务建模：** 把渗出液分割视作「逐像素二分类」（语义分割）。

**难点1 极端类别不平衡：** 渗出液前景仅占视野约 **0.43%**（测试集 271 万像素中仅约 1.16 万正样本）→ Accuracy 形同虚设（全预测背景即达 99.6%）。

**难点2 易混淆结构：** 视盘、血管反光、成像伪影「又亮又像渗出」，是误报主要来源。

**难点3 小样本：** 仅 47 张，深度模型易过拟合。

**难点4 光照不均：** 同一张图不同区域亮度差异大。



## 数据集与划分

数据集：e-optha EX，47 张带像素级渗出液标注的彩色眼底图。

沿用给定划分：32 训练 / 15 测试。

再从训练集切出约 18%（5–6 张）作验证集。

测试集全程隔离、仅最终评估用 → 无偏的泛化估计。

验证集用于模型选择（U-Net 早停）+ 判定阈值搜索 → 调参不碰测试集，避免数据泄漏。

小数据（47 张）下，三分法是结论可信的关键。

# 数据预处理

- ① **统一缩放  $672 \times 448$** ：尺寸统一便于批训练；保留约 1.5:1 长宽比；可被 32 整除以适配编码器。
- ② **FOV 视野掩膜**：排除眼底四周黑边，所有指标只在视野内统计。
- ③ **去光照（亮度归一化）**：大尺度背景估计并减除，消除不均匀照明。
- ④ **CLAHE 对比增强**：限制对比度自适应均衡，突出亮病灶。
- ⑤ **特征标准化**（LR/SVM 对尺度敏感）；U-Net 用 ImageNet 归一化 + 数据增强。

三种方法共享同一预处理，保证对比公平。

读图：原图 → 去光照+CLAHE → 金标准掩膜 → 渗出液叠加。



## 方法总览

设每个像素的特征向量为  $\mathbf{x} \in \mathbb{R}^{14}$ （14 维手工特征），标签  $y = \{1, 0\}$ （渗出=1，背景=0）。



统一评价口径：同预处理 · 同 32/15 划分，同指标计算 → 公平对比。  
三者均把分割视作逐像素二分类。

# 方法一：逻辑回归

LR 先对特征做线性打分 (logit) :

$$z = \mathbf{w}^T \mathbf{x} + b$$

再用 Sigmoid 把分数压到 (0,1) 作为"渗出"的概率:

$$P(y = 1 | \mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}}$$

对概率取 logit 可得对数几率 (log-odds) 关于特征线性:

$$\ln \frac{P(y = 1 | \mathbf{x})}{P(y = 0 | \mathbf{x})} = \mathbf{w}^T \mathbf{x} + b$$


决策边界  $\mathbf{w}^T \mathbf{x} + b = 0$  是特征空间里的一张超平面。

权重  $w_j$  的含义: 特征  $x_j$  每增加一个单位, 对数几率改变  $w_j \rightarrow$  系数即特征重要性。

交叉熵损失函数:

$$\mathcal{L}(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \omega_{y_i} [-y_i \ln p_i - (1 - y_i) \ln(1 - p_i)],$$

$$p_i = \sigma(\mathbf{w}^T \mathbf{x}_i + b)$$



LR 权重最大的是 **L (亮度)**、**b (黄度)**、**颜色通道**, 形态学特征权重很小  $\rightarrow$  说明「亮+黄」在线性层面已大体可分



## 方法二：SVM

### 3.2.1 软性间隔

该数据不可完全线性可分，故引入松弛变量 $\xi_i \geq 0$ ：

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_i \xi_i$$

$$\text{s.t. } y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

C 权衡"间隔大"与"分类错误少"。

### 3.2.2 精确核SVM会暴露问题：

精确核 SVM：训练约  $O(n^2 \sim n^3)$ ，预测约  $O(\text{数据像素} \times \text{支持向量})$ 。本任务训练/预测涉及**数百万像素**，支持向量上万，会直接卡死。



### 3.2.3 改用Nystroem核近似

从训练样本里取  $m$  个地标  $\{\mathbf{z}_j\}_{j=1}^m$  ( $m=200$ )，用地标间的核矩阵  $W_{jk} = K(\mathbf{z}_j, \mathbf{z}_k)$  构造**显式**特征映射

$$\hat{\phi}(\mathbf{x}) = W^{-1/2} \cdot [K(\mathbf{x}, \mathbf{z}_1), \dots, K(\mathbf{x}, \mathbf{z}_m)]^\top \in \mathbb{R}^m$$

使  $\hat{\phi}(\mathbf{x})^\top \hat{\phi}(\mathbf{x}') \approx K(\mathbf{x}, \mathbf{x}')$  (本质是对核 Gram 矩阵做低秩逼近)。映射后接**线性 SVM**，训练/预测降到约  $O(n \cdot m)$ 。

Hyperplanes carving up a high-dimensional space



## 方法三：U-Net

### 3.3.1 U-Net结构

**编码器（向下采样）：**使用预训练过的**ResNet34**，缓解梯度消失，重复 卷积块 + 池化/步长卷积，空间分辨率逐级减半、通道数逐级加倍 → 提取由浅到深的语义、扩大感受野。

**解码器（向上采样）：**用**转置卷积**或插值逐级上采样，恢复分辨率。

**跳跃连接：**把编码器同尺度的特征图拼接到解码器对应层。

### 3.3.2 损失函数


训练时用加权二元交叉熵（BCE）和Tversky Loss,

$$\mathcal{L}_{BCE} = -\frac{1}{N} \sum_i [w_p y_i \ln p_i + (1 - y_i) \ln(1 - p_i)]$$

$$TI = \frac{\sum_i p_i g_i}{\sum_i p_i g_i + \alpha \sum_i p_i (1 - g_i) + \beta \sum_i (1 - p_i) g_i}, \quad \mathcal{L}_{Tv} = 1 - TI$$

$\alpha = 0.3$ ,  $\beta = 0.7$ ，即更重罚假阴性（漏检），从而提升小病灶召回。

$$\mathcal{L} = w \cdot \mathcal{L}_{BCE} + (1 - w) \cdot \mathcal{L}_{Tv}$$



**优化：**AdamW (lr=1e-3) + 余弦退火 + 数据增强；60 轮，batch=8；按验证 Dice 选最佳权重。

结果总览





不计背景, *Dice*系数:  $Dice = \frac{2 \sum_i p_i g_i + \varepsilon}{\sum_i p_i + \sum_i g_i + \varepsilon} = \frac{2TP}{2TP + FP + FN}$

Dice损失:  $\mathcal{L}_{Dice} = 1 - Dice$


| 方法        | 学习时间 | Recall | Precision    | F1           | IoU          | Dice         | ROC-AUC      | PR-AUC       |
|-----------|------|--------|--------------|--------------|--------------|--------------|--------------|--------------|
| 逻辑回归 LR   | 3.0s | 0.428  | 0.048        | 0.086        | 0.045        | 0.086        | 0.842        | 0.152        |
| SVM (RBF) | 1.1s | 0.260  | 0.043        | 0.074        | 0.038        | 0.074        | 0.812        | 0.107        |
| U-Net     | 45s  | 0.434  | <b>0.536</b> | <b>0.480</b> | <b>0.316</b> | <b>0.480</b> | <b>0.926</b> | <b>0.687</b> |

U-Net 的 Dice 是传统方法的 **5–6 倍**、PR-AUC 约 **4.5–6 倍**；而传统方法学习时间仅 1–3 秒。

结果： ROC / PR 曲线 与 混淆矩阵



# 结果：定性分割对比



绿 = groundtruth,  
红 = 各方法预测。

**U-Net:** 红色预测贴合真实病灶，几乎无散点误报。

**LR / SVM:** 红点散布在血管、视盘周围 —— 大量误报。

典型案例（视盘明亮的样本）： LR/SVM 把视盘边缘误判为渗出， U-Net 正确避开。

# 结果原因与方法优缺点分析

**注意到** 三种方法召回率相近(~0.26–0.43)，关键在于误报：U-Net 假阳仅 4,383，而 LR/SVM 高达 6.7–9.9 万。根本差异——是否利用了空间上下文。

## 逻辑回归 LR

- 表现** Dice 0.086 · 精确率 0.048
- 原因** 线性模型只看单像素「亮+黄」，凡亮黄皆报 → 误报泛滥
- 优点** 训练极快(3s)、可解释(系数即特征贡献)
- 缺点** 线性边界、精确率极低


## SVM (RBF/Nystroem)

- 表现** Dice 0.074 · 精确率 0.043 (略逊 LR)
- 原因** 虽非线性，但仍只用局部特征与 Nystroem，非线性增益未完全体现
- 优点** 非线性、像素级可扩展
- 缺点** 受限局部特征、本任务未超 LR、对  $\gamma/C$  敏感

## U-Net (最优)

- 表现** Dice 0.480 · 精确率 0.536 (碾压)
- 原因** 卷积感受野利用空间上下文与形状，区分「真渗出 vs 像渗出的反光」→ 假阳骤降
- 优点** 精度最高、误报极少
- 缺点** 需 GPU、训练久、可解释性弱、依赖预训练

# 反思：非线性 SVM 为何反不及线性 LR？



**现象** SVM 验证集 Dice 0.159 远高于测试集 0.040（过拟合）；LR 验证 / 测试接近（0.104 / 0.089）。

**证据** 与阈值无关的测试 PR-AUC，SVM 在所有  $\gamma$  下均低于 LR（0.165）；且  $\gamma$  越大、非线性越强，PR-AUC 单调下降（0.137 $\rightarrow$ 0.091）。

**原因** 14 维“亮+黄”特征已近似线性可分；32 张小样本下，过高的模型复杂度只会过拟合。

## 结论

---

- **深度学习(U-Net)显著优于传统方法** Dice 提升约 5–6 倍；核心原因是利用空间上下文、大幅抑制误报。
- **传统方法(LR/SVM)胜在高效** 训练仅 1–3 秒、但受限局部特征，难辨「亮黄但非渗出」的结构。
- **极端不平衡需选对评价指标** 以 PR-AUC / Dice / 召回 为主；Accuracy 会被背景拉高而严重误导。
- **展望** 更强编码器(如 EfficientNet)、更高分辨率评测、形态学后处理进一步降假阳。



**谢谢 · 敬请批评指正**