

答辩口述稿（约 6.5-7 分钟）

用法：括号里的 (≈秒) 是该页建议时长，「」内是停顿/强调提示，可不念。整体语速放慢、自然些更稳。若时间偏紧，优先压缩第 5、6 页的细节。

第 1 页·封面 (≈25s)

各位老师好，我是<姓名>，我汇报的题目是《视网膜眼底图像的渗出液分割》。这个项目在 e-optha 数据集上，对比了三种方法——逻辑回归、SVM 和 U-Net。我想讲清楚的不只是"把分割做出来"，更是**为什么这样选方法，以及结果背后的原因**。汇报分四部分：背景、数据、方法、结果。

第 3 页·研究背景 (≈40s)

先看背景。糖尿病视网膜病变是全球主要的致盲病因之一，而它早期几乎没有症状，等到视力下降往往已经晚了，所以**早期筛查非常关键**。硬性渗出液，就是视网膜血管渗漏形成的亮黄色斑块，是这个病最重要的早期标志物之一。如果能把它自动分割出来，就能支撑大规模筛查、减轻医生阅片负担。但筛查图像量巨大、人工标注又很贵，所以自动化方法是临床上的刚需。

第 4 页·核心难点 (≈45s)

我们把渗出液分割建模成一个**逐像素的二分类**问题。它的难点很突出：第一，也是最关键的——**极端的类别不平衡**。渗出液前景只占视野的大约 0.43%，测试集 271 万个像素里，正样本只有一万一千多个。这意味着 Accuracy 几乎失效——一个什么都不做、全预测背景的模型，准确率都有 99.6%。第二，视盘、血管反光、成像伪影，这些结构「又亮又像渗出」，是误报的主要来源。第三，数据只有 47 张，深度模型容易过拟合；第四，成像光照不均。这几个难点，直接决定了我们后面的方法设计和指标选择。

第 5 页·数据与划分 (≈35s)

数据用的是 e-optha EX，47 张带像素级标注的眼底图。我们沿用给定的 32 训练、15 测试划分，并额外从训练集里切出约 18% 作验证集。原因是：测试集要**全程隔离**、只在最后评估一次，才能得到无偏的泛化估计；验证集用来做模型选择和阈值搜索，保证调参不碰测试集、不产生数据泄漏。在只有 47 张的小数据下，这种三分法是结论可信的关键。

第 6 页·预处理 (≈35s)

预处理做了几步：统一缩放到 672×448；用 FOV 掩膜去掉四周黑边、指标只在视野内统计；做去光照消除不均匀照明；再用 CLAHE 增强局部对比、突出亮病灶；对 LR 和 SVM 还做了特征标准化。这里要强调：**三种方法共享同一套预处理和同一划分**，这样对比才公平。右边这张图就是从原图、到去光照加 CLAHE、到金标准、再到叠加的全过程。

第 7 页·方法总览 (≈20s)

我们选的三种方法正好构成一个递进：逻辑回归是线性的，SVM 通过核引入非线性，U-Net 是深度学习。前两种是逐像素用 14 维手工特征做分类，U-Net 则是端到端地利用空间上下文。

第 8 页·方法一 逻辑回归 (~40s)

先说逻辑回归。它先对 14 维特征做一个线性打分，再用 Sigmoid 压到 0 到 1 作为"是渗出"的概率，训练目标是带类别权重的交叉熵加 L2 正则。它的好处是快、而且**可解释**——权重本身就是特征重要性。从这张系数图能看到，权重最大的是亮度 L、黄度 b 和颜色通道，形态学特征权重很小。这说明 LR 本质上在用「够不够亮、够不够黄」来线性划界——这也埋下了它误报多的伏笔。

第 9 页·方法二 SVM (~40s)

第二种是 SVM。它的思想是找一个**间隔最大**的分离超平面，通过 RBF 核把数据映射到高维空间，从而得到非线性的判别边界。但精确的核 SVM 在像素级是算不动的——训练是平方甚至立方复杂度，预测开销也极大。所以我们用了 **Nystroem 核近似**：取 200 个地标点构造一个显式的近似特征映射，再接线性 SVM、用 SGD 训练。这样既保留了非线性，又能扩展到几百万像素。

第 10 页·方法三 U-Net (~55s)

第三种是 U-Net，编码器-解码器加跳跃连接的全卷积网络。关键有三点：一是编码器用了在 ImageNet 上**预训练的 ResNet34**，靠迁移学习缓解我们只有 47 张的小样本问题；二是**跳跃连接**，把编码器的细节特征补回解码器，对小而散的病灶定位很重要；三是**损失函数**，我们用加权 BCE 加 Tversky 的组合，把假阴的惩罚调得比假阳更重，专门提升小病灶召回。训练上用 AdamW、余弦退火、数据增强，跑 60 轮，按验证 Dice 选最好的模型。最根本的一点是——卷积的**感受野**让它能看到一个像素周围的上下文和形状，而不是孤立地看单个像素。

第 11 页·结果总览 (~35s)

接下来是结果。看这张总表：U-Net 在几乎所有关键指标上都大幅领先——Dice 达到 0.48，是传统方法的**五到六倍**；PR-AUC 0.69，大约是它们的四点五到六倍。代价是训练时间——U-Net 是 45 秒，而 LR、SVM 只要一到三秒。

第 12 页·曲线与混淆矩阵 (~40s)

再看曲线和混淆矩阵。有意思的是，ROC 上三种方法的 AUC 都不低，都在 0.81 到 0.93——这是因为背景的真阴性太多，把差距压平了。真正拉开差距的是 PR 曲线：U-Net 的平均精度 0.69，远远甩开 LR 的 0.15 和 SVM 的 0.11。混淆矩阵更直接：U-Net 的假阳性只有 4383 个，而 LR 有将近十万、SVM 也有六万多。

第 13 页·定性对比 (~30s)

这张定性图最直观。绿色是金标准，红色是预测。可以看到，U-Net 的红色预测紧紧贴合真实病灶、几乎没有散点；而 LR 和 SVM 的红点散布在血管和视盘周围，全是误报。特别是这个视盘很亮的例子，LR、SVM 直接把视盘边缘误判成渗出，而 U-Net 正确地避开了。

第 14 页·结果原因分析【重点】 (~60s)

那为什么是这样的结果？这是我想重点讲的一页。请注意一个关键事实：三种方法的**召回率其实很接近**，都在 0.26 到 0.43 之间——也就是说，"找到多少"差不多，真正的胜负手是「**误报多少**」。U-Net 的假阳只有四千多，而 LR、SVM 高达六到十万。为什么差这么多？因为 LR 和 SVM 是逐像素地只看局部特征，凡是又亮又黄的就报，自然把视盘、反光全误判了；而 U-Net 通过感受野看到了**空间上下文和形状**，能区分"真渗出"和"只是看起来像渗出的反光"。另外，

SVM 反而略低于 LR，是因为「亮+黄」在线性层面已经大体可分，而 Nystroem 近似又没精调参数，非线性优势没体现出来。这些都说明：**手工特征加逐像素分类，是有天花板的。**

第 15 页·结论 (~30s)

最后总结三点：第一，深度学习在这个任务上显著优于传统方法，Dice 提升五到六倍，核心原因是利用了空间上下文、大幅压低误报；第二，传统方法也有价值——训练快、可解释，只是受限局部特征；第三，极端不平衡下一定要**选对指标**，看 PR-AUC、Dice 和召回，而不能被虚高的 Accuracy 误导。未来可以用更强的编码器、更高分辨率、加形态学后处理，进一步降低误报。

第 16 页·致谢 (~10s)

我的汇报到此结束，谢谢各位老师，请批评指正。

临场提示

- 总时长约 6.5-7 分钟；若提示快超时，砍掉第 5、6 页的细节（一句话带过"做了标准的去光照、CLAHE 等预处理，三法共享以保证公平"）。
 - **三个必须讲清的点**：① 类别不平衡（第 4 页）；② 召回相近、误报是胜负手（第 14 页）；③ 上下文是 U-Net 取胜的根因（第 14 页）。其余可适当加速。
 - 念到**数字**时略放慢、略加重（0.48、五到六倍、四千 vs 十万），评委对数字最敏感。
 - 第 14 页是高光页，建议在这里**停顿一下、放慢**，眼神交流。
 - 别照念公式；公式让 PPT 去显示，你用"思想"把它说出来即可。
-

Q&A 预案（参考答法）

Q：为什么 SVM 反而不如 LR？ A：两个原因。一是「亮+黄」这个特征在线性层面已经大体可分，非线性带来的增益本就有限；二是我们用的是 Nystroem 核近似、且没有对 γ 和 C 做精细网格搜索，所以 RBF 的非线性优势没有充分发挥。如果精调参数或加大地标数，SVM 可能小幅回升，但受限"只用局部特征"，难有质变。

Q：为什么三种方法的最优阈值都落在 0.95？ A：阈值是在验证集上按 F1 搜出来的。它顶到搜索上界，说明传统方法正负样本的预测得分**高度重叠**——即便取最保守的阈值，精确率也只有 0.05 左右。这恰恰反映了手工特征的可分性瓶颈；U-Net 在 0.95 仍有 0.54 的精确率，说明它的得分分布区分度好得多。

Q：如何进一步降低误报 / 提升性能？ A：几个方向：对 U-Net 输出做形态学后处理去掉孤立小点；显式加入视盘检测并屏蔽该区域；用更强的编码器（如 EfficientNet）和更高分辨率；以及用 Focal-Tversky 等更强的不平衡损失。

Q：小样本只有 47 张，怎么保证不过拟合？ A：三方面：用 ImageNet 预训练编码器做迁移学习；翻转、旋转、亮度抖动等数据增强；以及用独立验证集按 Dice 早停选模型。训练曲线显示验证 Dice 上升后进入平台、没有回落，说明没有明显过拟合。

Q：为什么用 PR-AUC 而不是 Accuracy / ROC-AUC？ A：因为前景只占 0.43%，背景的真阴性会让 Accuracy 虚高到 0.96 以上、也会让 ROC-AUC 偏乐观；而 PR 曲线只关注正类的查准-查全权衡，对极端不平衡更敏感、更能反映真实性能。