

# 眼底渗出液分割·答辩演讲稿（约7分钟）

节奏提示：全文约1700字，按从容语速约7分钟。若现场偏紧张语速会变快，可适当放慢；若超时，优先精简【方法·LR/SVM】与【原因分析】两段的细节。每段开头方括号为对应幻灯片。

【开场·slide 1】各位老师好，我是\_\_\_\_\_（自报姓名），我汇报的题目是《视网膜眼底图像的渗出液分割》。本研究在统一的实验口径下，系统对比了逻辑回归、SVM两种传统机器学习方法，与U-Net深度学习方法，重点分析它们在精度、误报和效率上的差异。

【研究背景·slide 3】首先是背景。糖尿病视网膜病变是全球主要致盲病因之一，而且早期往往没有症状，所以早筛早治非常关键。硬性渗出液，是视网膜血管渗漏形成的亮黄色脂质斑块，正是它最重要的早期标志物之一。对渗出液做自动分割，可以支撑大规模筛查、量化病情、减轻医生阅片负担。而筛查图像量巨大、人工标注又很昂贵，所以自动化方法是临床刚需。

【任务与难点·slide 4】我们把渗出液分割建模成逐像素的二分类问题。它有几个核心难点：第一，极端类别不平衡——渗出液前景只占视野的约0.43%，测试集271万像素里只有约1.16万正样本，这意味着Accuracy几乎失效，因为全部预测成背景就能达到99.6%；第二，视盘、血管反光这些结构“又亮又像渗出”，是误报的主要来源；第三是只有47张图的小样本；第四是光照不均。这几点贯穿了我后面所有的设计。

【数据与划分·slide 5】数据集用的是e-optha EX，47张带像素级标注的彩色眼底图。我沿用官方给定的32训练、15测试划分，再从训练集里切出约18%作验证集。这里我特别强调：测试集全程隔离、只在最后评估时用一次；验证集只用于模型选择和阈值搜索。在47张这种小数据下，严格的三分法是结论可信的关键。

【预处理·slide 6】预处理分五步：统一缩放到672×448，便于批训练、又能被32整除以适配编码器；用FOV掩膜去掉黑边，所有指标只在视野内统计；做去光照的亮度归一化，消除照明不均；用CLAHE增强对比、突出亮病灶；最后针对不同模型做归一化。关键是一一三种方法共享同一套预处理，保证对比是公平的。

【方法总览·slide 7】方法上我对比三种：逻辑回归是线性分类器，用14维手工特征；SVM用RBF核做非线性；U-Net是深度学习，用预训练编码器加跳跃连接。三者都在同样的预处理、同样的划分、同样的指标下评测。

【传统方法·slides 8-9】传统方法这边，我为每个像素设计了14维手工特征，核心思想是把渗出液刻画成“又亮又黄的小结构”，包括颜色、亮度、局部对比、形态学Top-hat等。逻辑回归用加权交叉熵训练，简单而且可解释。SVM这边，由于百万像素上精确核SVM不可行，我采用Nyström核近似——选200个地标像素，把特征映射到200维，再做线性SVM，把复杂度降下来。

【U-Net·slide 10】U-Net这边，因为只有32张训练图，我用ImageNet预训练的ResNet34作编码器，靠迁移学习缓解过拟合。针对极端不平衡，损失用加权BCE加Tversky组合，并把Tversky的 $\beta$ 设得比 $\alpha$ 大，加重对漏检的惩罚，来提升小病灶的召回。优化用AdamW加余弦退火，按验证集Dice选最佳权重。

【结果总览·slide 11】来看结果。U-Net 在 Dice、IoU、精确率、PR-AUC 上全面领先：它的 Dice 是 0.480，约为传统方法的 5 到 6 倍；而传统方法的学习时间只有 1 到 3 秒，U-Net 要 45 秒。这里要提醒一句，三种方法 Accuracy 都在 0.96 以上，但这个数字毫无参考价值，正是前面说的不平衡造成的假象。

【曲线与混淆矩阵·slide 12】再看曲线。三种方法的 ROC-AUC 都挺高，但这是被海量真阴性压缩出来的假象；真正拉开差距的是 PR 曲线——U-Net 的 PR-AUC 是 0.687，而 LR、SVM 只有 0.15 和 0.11。结合混淆矩阵就更清楚了：三者的召回率其实很接近，但误报天差地别——U-Net 的假阳只有 4,383 个，LR 和 SVM 却高达 6.7 万到 9.9 万。

【定性结果·slide 13】定性图上一目了然：U-Net 的红色预测紧贴真实病灶、几乎没有散点；而 LR、SVM 的红点散布在血管、视盘周围，全是误报。尤其在视盘明亮的样本里，传统方法会把视盘边缘误判成渗出，U-Net 却能正确避开。

【原因分析 +  $\gamma$  反思·slide 14】那么胜负手到底是什么？就是有没有利用空间上下文。LR、SVM 只看单个像素亮不亮、黄不黄，所以凡是又亮又黄的都报，误报泛滥；而 U-Net 借助卷积感受野利用了空间上下文和形状，能区分“真渗出”和“像渗出的反光”，假阳因此骤降。这里还有个有意思的现象：非线性的 SVM 反而不如线性的 LR。为排除调参的影响，我对 SVM 的核宽度  $\gamma$  做了网格搜索，结果它在测试集上所有  $\gamma$  下都低于 LR，而且  $\gamma$  越大、非线性越强，测试性能反而单调下降。原因是我这 14 维“亮加黄”的特征在线性层面已经大体可分，而在仅 32 张的小样本上，过高的模型复杂度只会过拟合——这正是偏差方差权衡的直接体现。

【结论·slide 15】最后总结三点：第一，深度学习显著优于传统方法，Dice 提升约 5 到 6 倍，核心在于利用空间上下文、大幅抑制误报；第二，传统方法胜在高效，训练只要 1 到 3 秒，但受限局部特征；第三，在极端不平衡场景下，一定要选对评价指标，以 PR-AUC、Dice、召回为主，不能被 Accuracy 误导。未来可以换更强的预训练编码器、用更高分辨率，再加形态学后处理，进一步降低假阳。

【致谢·slide 16】我的汇报到此结束，感谢各位老师，敬请批评指正。

---

## 答辩可能被追问的问题·速答提示（备用，非正文）

- 为什么 U-Net 召回和传统法差不多，却说它好得多？——因为分割好坏看的是召回与精确率的综合（Dice/PR-AUC），三者召回相近，但 U-Net 误报只有传统法的二十分之一左右，所以 Dice 是其 5-6 倍。
- 为什么不用 Accuracy？——前景仅 0.43%，全预测背景 Accuracy 也有 99.6%，它在极端不平衡下完全失真。
- 为什么非线性 SVM 不如线性 LR？——见正文  $\gamma$  网格搜索：特征近似线性可分 + 小样本过拟合， $\gamma$  越大测试越差。
- 小样本只有 47 张，结论可信吗？——用了严格三分法、测试集全程隔离、统一口径，结论反映的是相对趋势而非绝对上限。
- U-Net 为什么用预训练 ResNet34？——32 张训练图太少，迁移学习能显著缓解过拟合。