

答辩理论问答速记（机器学习大作业）

每条都是可直接说出口的简短解释。老师追问哪点就答哪点；不必背全，理解后用自己的话说更自然。

0. 一句话本质区别（万能开场）

LR 是**线性**分类器、SVM 用核做**非线性**、U-Net 是能看**空间上下文**的深度网络；前两者逐像素只看局部手工特征，U-Net 端到端利用邻域结构——这正是它误报远少、性能领先的根因。

一、逻辑回归（LR）

Q：为什么用 Sigmoid 函数？ 因为线性打分 $w^T x + b$ 的范围是整个实数轴，而我们要的是 0-1 的概率。Sigmoid 正好把实数压到 (0,1)，而且它是 logit 函数的反函数——等价于假设"对数几率关于特征线性"。

Q：为什么用交叉熵损失，而不是均方误差？ 两点：一是交叉熵就是伯努利分布的极大似然，概率解释自然；二是 Sigmoid 配交叉熵时损失是**凸的**、梯度是 $(p-y)x$ 不含 Sigmoid 的导数项，不会在饱和区梯度消失；而 Sigmoid 配 MSE 非凸、且预测越错梯度反而越小，学不动。

Q：L2 正则起什么作用？ 限制权重幅度、防止过拟合、提升泛化；从贝叶斯角度等价于给权重加了一个高斯先验。我们的参数 C 是正则强度的倒数。

Q：怎么处理类别不平衡？ 用 `class_weight=balanced`，给正类（渗出）更大的损失权重，与类别频率成反比，避免模型为了 Accuracy 全预测背景。

二、支持向量机（SVM）

Q：什么是"间隔"，为什么要最大化？ 间隔是离超平面最近的样本到超平面的距离。最大化间隔意味着分类决策更有"余量"、对噪声更鲁棒——这对应结构风险最小化，泛化通常更好。

Q：什么是支持向量？ 就是落在间隔边界上或边界内（被错分/被容忍）的那些样本。最终的超平面**只由它们决定**，其它远离边界的样本去掉也不影响解。

Q：核技巧为什么能 work？ 因为 SVM 的对偶问题只依赖样本之间的**内积**。我们用核函数 $K(x, x')$ 直接代替内积，就相当于在一个隐式的高维空间里做线性划分（即原空间的非线性边界），而**不需要显式算出那个高维映射**。Mercer 条件保证：只要核是对称半正定的，它就一定对应某个特征空间的内积。

Q：RBF 核里的 γ 控制什么？ RBF 核 $\exp(-\gamma \|x - x'\|^2)$ 衡量两点的相似度。 γ 大 $\rightarrow$ 作用半径小、边界很尖锐、容易过拟合； γ 小 $\rightarrow$ 更平滑、可能欠拟合。

Q：软间隔里的 C 呢？ C 权衡"间隔尽量大"和"分类错误尽量少"。C 大 $\rightarrow$ 更不容忍错分、边界更硬（低偏差高方差）；C 小 $\rightarrow$ 更宽容、更平滑。

Q：Nystroem 近似到底做了什么？（本实验重点） 精确核 SVM 训练是 $O(n^2 \sim n^3)$ 、预测要遍历所有支持向量，几百万像素根本算不动。Nystroem 的思想是：取 m 个"地标"样本，用它们对整个核（Gram）矩阵做**低秩近似**，从而得到一个**显式的 m 维特征**，让 $\hat{\phi}^T(x)\hat{\phi}(x') \approx K(x, x')$ ；之后接一个**线性 SVM** 即可，复杂度降到约 $O(n \cdot m)$ 。我取 $m=200$ 。

Q：为什么本实验 SVM 反而不如 LR？ 因为"亮+黄"这个判据在线性层面已经大体可分，非线性的增益本就有限；加上 Nystroem 是近似、且我没有对 γ/C 做精细网格搜索，所以 RBF 的优势没发挥出来。精调或加大 m 可能小幅回升，但仍受限于"只用局部特征"。

三、U-Net 与深度学习

Q：卷积相比全连接好在哪？ 局部连接 + 权值共享，带来平移等变性、参数量小、天然适合图像；同一个卷积核在全图滑动，能复用模式。

Q：什么是感受野？为什么关键？ 感受野是某个输出神经元"能看到"的输入区域。网络越深、下采样越多，感受野越大，高层神经元就能利用一个像素**周围的上下文和形状**来判断。这正是 U-Net 能区分"真渗出"和"像渗出的反光/视盘"的根本原因，也是它对逐像素的 LR/SVM 的本质优势。

Q：跳跃连接为什么重要？ 编码器下采样会丢掉精细的空间位置信息。跳跃连接把编码器同尺度的高分辨率特征直接拼到解码器，把这些细节补回来，对**小而散的病灶**边界定位特别重要。

Q：转置卷积/上采样是干什么的？ 解码器需要把低分辨率特征图逐级放大、恢复到原图尺寸，用转置卷积或插值上采样完成。

Q：BatchNorm 的作用？ 对每一批激活做标准化，稳定并加速训练、允许用更大学习率，还有轻微的正则效果。

Q：ResNet 的残差连接解决什么？ 让网络学"残差" $F(x)+x$ 。这缓解了深层网络的梯度消失和退化问题，使得很深的网络也能训得动。

Q：迁移学习为什么对小样本有效？ 低层卷积学到的边缘、纹理等特征是通用的。用 ImageNet 预训练权重相当于一个很好的初始化，在我们只有 47 张图时，比从零训练更不容易过拟合（从零训练我也试过，难收敛）。

Q：为什么不只用 BCE，还要加 Tversky？ 极端不平衡下，逐像素 BCE 会被海量背景主导。Dice/Tversky 这类**重叠度损失不计真阴性**，对不平衡更鲁棒。Tversky 还能调假阳/假阴的权重，我取 $\alpha=0.3$ 、 $\beta=0.7$ ，即更重罚漏检，从而提升小病灶召回。

Q：AdamW 和余弦退火？ Adam 用一阶/二阶矩做自适应学习率，收敛快；AdamW 把权重衰减从梯度更新里"解耦"出来，正则更正确。余弦退火让学习率沿余弦曲线平滑下降，后期小步细调、收敛更稳。

四、通用 ML 概念（很可能被问）

Q：为什么不用准确率（Accuracy）评价？ 前景只占 0.43%，全预测背景准确率就有 99.6%——它被背景主导、毫无区分度。所以我们以 PR-AUC、Dice、召回为主。

Q：ROC 和 PR 曲线的区别？为什么强调 PR？ ROC 用到真阴性，在极端不平衡时会显得过于乐观（三种方法 AUC 都 0.8+）；PR 曲线只看正类的查准-查全权衡，对不平衡更敏感，所以差距在 PR 上才真正拉开（U-Net 0.69 vs 0.15/0.11）。

Q：判定阈值怎么定的？ 在验证集上按 F1 最优搜索得到，全程不碰测试集，避免数据泄漏。

Q：怎么防止过拟合？ 预训练初始化 + 数据增强 + L2/权重衰减 + 用验证集 Dice 早停选模型。训练曲线显示验证 Dice 升到平台后没回落，说明没有明显过拟合。

Q：从偏差-方差角度看三种方法？ LR 是高偏差模型（太简单，欠拟合复杂边界）；SVM 容量更大但本任务没调好；U-Net 容量最大，本会高方差，但靠预训练+增强+早停把方差压住了，所以泛化最好。

Q：14 维特征是怎么来的、为什么这么选？ 基于先验"渗出是又亮又黄的小结构"：颜色（RGB、LAB 的 a/b、HSV 的 S/V）、局部对比、局部标准差（纹理）、两个尺度的 Top-hat（提亮结构的形态学）、梯度幅值。LR 系数显示亮度/黄度贡献最大，验证了这个先验。